OMER BOUEKE

Ingénieur IA, HPC & MLOps : Machine Learning, LLM, déploiement, programmation GPU

+33 7 51 01 45 91 | bouekeomerbocassa@gmail.com | Mobilité France entière
Portfolio : bokassa09.github.io | LinkedIn : linkedin.com/in/omer-bokassa-boueke-9674a331a

PROFIL

Diplômé du Master Informatique, parcours HPC / IA de l'Université de Perpignan, je recherche un poste en Machine Learning, MLOps ou Data Science, à l'interface de l'IA et du calcul haute performance. Je conçois, développe et déploie des modèles et des pipelines IA, de l'expérimentation à la mise en production. Stage de recherche appliquée à Inria / INRAE (pipeline ML sur supercalculateur), programmation GPU en CUDA et projets IA déployés en ligne (FastAPI, Docker, CI/CD).

COMPÉTENCES

Machine Learning & Deep Learning : PyTorch, TensorFlow / Keras, Scikit-learn, CatBoost, Optuna, SHAP, CNN, LSTM, Transformer, Autoencoder, apprentissage supervisé, non supervisé et semi-supervisé, séries temporelles, NLP, vision par ordinateur

IA générative & LLM : Hugging Face Transformers, RAG, LangChain, LangGraph, ChromaDB, Groq API, prompt engineering, évaluation de la qualité des réponses (Faithfulness, Answer Relevancy)

HPC & GPU : SLURM, MPI, OpenMP, CUDA (portage CPU vers GPU), profiling (Gprof, Perf), debug (GDB, Valgrind), C, Linux

MLOps & Déploiement : MLflow (Tracking, Model Registry), Kedro, FastAPI, Docker, CI/CD (GitHub Actions, pytest), Render, Hugging Face Spaces

Data & Langages : Python, SQL, SQLite, Pandas, NumPy, Apache Spark / PySpark, MongoDB, Git, Bash

Langues : Français (natif), Anglais (B2 : lecture scientifique et technique)

EXPÉRIENCE PROFESSIONNELLE

Stagiaire Data Science & Machine Learning — Fév. à août 2026

Inria / INRAE, Rennes

- Pipeline ML complet sur supercalculateur : préparation de données scientifiques réelles (9 variables climatiques, environ 27 millions de valeurs chacune), modélisation supervisée et non supervisée, suivi des expérimentations avec MLflow (Tracking et Model Registry), documentation pour des équipes pluridisciplinaires.
- Temps d'exécution réduit de 3 h à 7 min (25 fois plus rapide) grâce à la parallélisation HPC / SLURM sur 60 cœurs et à l'optimisation des accès aux données.

Stack : Python, Scikit-learn, MLflow, Pandas, NumPy, Bash, Git, HPC / SLURM

Stagiaire Deep Learning — Mai à juil. 2025

LAMPS, Université de Perpignan

- Module Python de différentiation automatique (forward et backward) par surcharge d'opérateurs, validé face à JAX, PyTorch et TensorFlow.

Stack : Python, PyTorch, TensorFlow, JAX, NumPy

PROJETS

Breast Cancer Classifier, Pipeline MLOps End to End — 2026

- **Problème :** entraîner un classifieur médical avec seulement 2 % de données étiquetées. **Approche :** Self-Training semi-supervisé. **Résultats :** +6,1 points d'accuracy, Recall de 100 % sur la classe maligne, 7 runs suivis avec MLflow, Model Registry (Staging vers Production).
- API REST FastAPI avec stockage SQLite des prédictions en temps réel, CI/CD GitHub Actions et pytest, déployé sur Hugging Face Spaces.

Stack : Scikit-learn, MLflow, FastAPI, Docker, SQLite, GitHub Actions

Customer Churn Intelligence Platform — 2026

- Prédiction du churn bancaire : CatBoost optimisé avec Optuna (ROC-AUC 87,5 %, Recall 69 %, F1 61 %, 10 000 clients), explications SHAP en langage naturel, recommandation générée par LLM (Groq).
- Pipeline Kedro, MLflow (Registry Staging vers Production), API FastAPI, dashboard Dash, Docker, CI/CD GitHub Actions, déployé sur Render.

RAG Assistant : LangChain, LangGraph & Groq — 2026

- RAG agentique (LangGraph à 3 nœuds, ChromaDB, embeddings HuggingFace, Groq), interface Streamlit, Docker, déployé sur Render. Évaluation maison (LLM juge, 3 questions) : Faithfulness 0,67, Answer Relevancy 0,95.

Programmation GPU : portage CPU vers GPU (CUDA) — 2026

- **Problème :** accélérer un code de traitement d'images en exploitant la puissance de calcul massif des GPU NVIDIA. Portage complet d'un code CPU vers CUDA : gestion de la mémoire GPU, optimisation des transferts host/device, analyse des gains de performance par rapport à l'exécution séquentielle. Démonstration directe de la maîtrise des architectures GPU parallèles.
- Excellente note obtenue. Compétence directement applicable au déploiement et à l'optimisation de modèles IA (inférence, fine-tuning) sur architectures GPU HPC.

Stack : C, CUDA, GPU NVIDIA, Python

Parallélisation HPC : MPI et OpenMP (calcul de pi) — 2025 : 2026

- Implémentation indépendante de deux approches, MPI et OpenMP, mesure des temps d'exécution séquentiel / MPI / OpenMP et analyse de scalabilité sur cluster HPC.

Stack : C, MPI, OpenMP, Linux, SLURM

Benchmark Deep Learning : architectures sur séries temporelles — 2026

- Comparaison de 4 architectures (CNN, LSTM, Transformer, Autoencoder) dans des conditions identiques et reproductibles (MSE / MAE), analyse des goulots d'étranglement et guide de bonnes pratiques réutilisable.

Stack : Python, PyTorch, TensorFlow, Scikit-learn

FORMATION

Master Informatique, parcours HPC / IA — 2024 : 2026

Université de Perpignan Via Domitia · Moyenne 14,70/20 · Mention Bien · 2e de promotion

- HPC / SLURM, calcul distribué, MPI / OpenMP, CUDA, Machine Learning, Deep Learning, NLP, vision par ordinateur, Transformers, Big Data (Spark, MongoDB).